

**Pravilo bodovanja zadataka**

Svaki točno odgovoreni zadatak donosi 5 bodova, svaki netočno odgovoreni -2 boda, a neodgovoreni zadaci donose 0 bodova.

**Zadatak 1:** Komunikacijskim kanalom prenose se tri jednostavne poruke, 'a', 'b' i 'c', generirane iz skupa simbola  $X = \{a, b, c\}$ . Vjerojatnosti pojavljivanja simbola su:  $p(a) = p(b) = 2p(c)$ . Matrica uvjetnih vjerojatnosti prijelaza u kanalu zadana je na sljedeći način:

$$\left[ p(y_j | x_i) \right] = \begin{bmatrix} 0,7 & 0,1 & 0,2 \\ 0,2 & 0,7 & 0,1 \\ 0,1 & 0,2 & 0,7 \end{bmatrix}$$

Odredite transinformaciju u kanalu.

a) 0,4096 bit/simbol

b) 1,522 bit/simbol

c) 0,381 bit/simbol

d) 1,566 bit/simbol

*Postupak rješavanja:*

Iz uvjeta da vjerojatnosni skup bude potpun, slijedi:

$$p(a) = p(x_1) = 0,4$$

$$p(b) = p(x_2) = 0,4$$

$$p(c) = p(x_3) = 0,2$$

odnosno

$$\left[ p(x_i, y_j) \right] = \begin{bmatrix} 0,28 & 0,04 & 0,08 \\ 0,08 & 0,28 & 0,04 \\ 0,02 & 0,04 & 0,14 \end{bmatrix}$$

Zbrajanjem po stupcima matrice združenih vjerojatnosti dobivamo:



$$\left[ p(y_j) \right] = [0,38 \quad 0,36 \quad 0,26]$$

Naposljetku, transinformaciju dobivamo iz:

$$I(X; Y) = \sum_{i=1}^3 \sum_{j=1}^3 p(x_i, y_j) \log \frac{p(x_i, y_j)}{p(x_i)p(y_j)} = 0,4096 \text{ bit/simbol}$$

**Zadatak 2:** Diskretno bezmemorijsko izvorište generira simbole iz skupa  $X = \{0, 1, 2\}$  s vjerojatnostima pojavljivanja  $p(0) = 0,25$ ,  $p(1) = 0,25$  i  $p(2) = 0,5$ . Svaki od izvorišnih simbola istodobno se šalje dvama diskretnim komunikacijskim kanalima, prikazanim na slici, čiji su

izlazi  $y_j$ ,  $j = 1, 2$ , odnosno  $z_k$ ,  $k = 1, 2$ . Odredite omjer transinformacije  $I(X; Z)$  prema transinformaciji  $I(X; Y)$ .



- a) 0
- b) 1
- c) 2**
- d) 0,5

Postupak rješavanja:

$$\begin{bmatrix} p(y_j | x_i) \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0,5 & 0,5 \end{bmatrix}$$

$$\begin{bmatrix} p(x_i, y_j) \end{bmatrix} = \begin{bmatrix} p(x_i) p(y_j | x_i) \end{bmatrix} = \begin{bmatrix} 0,25 & 0 \\ 0 & 0,25 \\ 0,25 & 0,25 \end{bmatrix}$$

$$\begin{bmatrix} p(y_j) \end{bmatrix} = [0,5 \quad 0,5]$$

$$H(Y) = - \sum_{j=1}^2 p(y_j) \log_2 p(y_j) = - (0,5 \log_2 0,5 + 0,5 \log_2 0,5) = 1 \frac{\text{bit}}{\text{simbol}}$$

$$\begin{bmatrix} p(z_k | x_i) \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$\begin{bmatrix} p(x_i, z_k) \end{bmatrix} = \begin{bmatrix} p(x_i) p(z_k | x_i) \end{bmatrix} = \begin{bmatrix} 0,25 & 0 \\ 0,25 & 0 \\ 0 & 0,5 \end{bmatrix}$$

$$\begin{bmatrix} p(z_k) \end{bmatrix} = [0,5 \quad 0,5]$$

$$H(Z) = - \sum_{k=1}^2 p(z_k) \log_2 p(z_k) = - (0,5 \log_2 0,5 + 0,5 \log_2 0,5) = 1 \frac{\text{bit}}{\text{simbol}}$$

$$I(X; Y) = H(Y) - H(Y | X)$$

$$H(Y | X) = - \sum_{i=1}^3 \sum_{j=1}^2 p(x_i, y_j) \log_2 p(y_j | x_i) = - (-0,25 - 0,25) = 0,5 \frac{\text{bit}}{\text{simbol}}$$

$$I(X; Y) = 1 - 0,5 = 0,5 \frac{\text{bit}}{\text{simbol}}$$

$$I(X;Z) = H(Z) - H(Z|X)$$

$$H(Z|X) = -\sum_{i=1}^3 \sum_{j=1}^2 p(x_i, z_k) \log_2 p(z_k | x_i) = 0 \frac{\text{bit}}{\text{simbol}}$$

$$I(X;Z) = 1 - 0 = 1 \frac{\text{bit}}{\text{simbol}}$$

$$\frac{I(X;Z)}{I(X;Y)} = \frac{1}{0,5} = 2$$

**Zadatak 3:** Diskretno bezmemorijsko izvorište generira simbole iz skupa  $X = \{x_1, x_2, x_3, x_4\}$ . Vjerojatnosti pojavljivanja simbola su sljedeće:  $p(x_1) = 0,4$ ,  $p(x_2) = 0,3$ ,  $p(x_3) = 0,2$  i  $p(x_4) = 0,1$ . Izračunajte količinu informacije koja se prenosi u poruci  $x_1 x_2 x_1 x_3$ .

a) 6,70 bit/poruka

b) 7,386 bit/poruka

c) 2,043 bit/poruka

d) 3,35 bit/poruka

*Postupak rješavanja:*

$$I(x_i) = -\log_2 p(x_i) \text{ bit/simbol}$$

$$I(x_1 x_2 x_1 x_3) = -\log_2 (p(x_1) \cdot p(x_2) \cdot p(x_1) \cdot p(x_3))$$

$$I(x_1 x_2 x_1 x_3) = -\log_2 (0,4 \cdot 0,3 \cdot 0,4 \cdot 0,2)$$

$$I(x_1 x_2 x_1 x_3) = 6,70 \text{ bit/poruka}$$

**Zadatak 4:** Zadano je diskretno bezmemorijsko izvorište koje generira simbole  $x_i$ ,  $i = 1, 2, \dots, n$ . Svi simboli su jednako vjerojatni i maksimalna entropija izvorišnog skupa simbola iznosi  $H(X) = 3,4594$  bit/simbol. Odredite za koliko se promijeni efikasnost koda prilikom kodiranja skupa simbola ternarnim Huffmanovim kodom u odnosu na kodiranje istog skupa simbola binarnim Huffmanovim kodom.

a) smanji se za 0,9755

b) smanji se za 0,0151

c) poveća se za 0,9604

d) poveća se za 0,0151

*Postupak rješavanja:*

i) Potrebno je odrediti broj izvorišnih simbola  $n$ . Kako su svi simboli jednako vjerojatni možemo zapisati:

$$p(x_1) = p(x_2) = \dots = p(x_n) = \frac{1}{n}$$

Iz prethodne jednakosti i poznate entropije na ulazu računamo broj simbola:

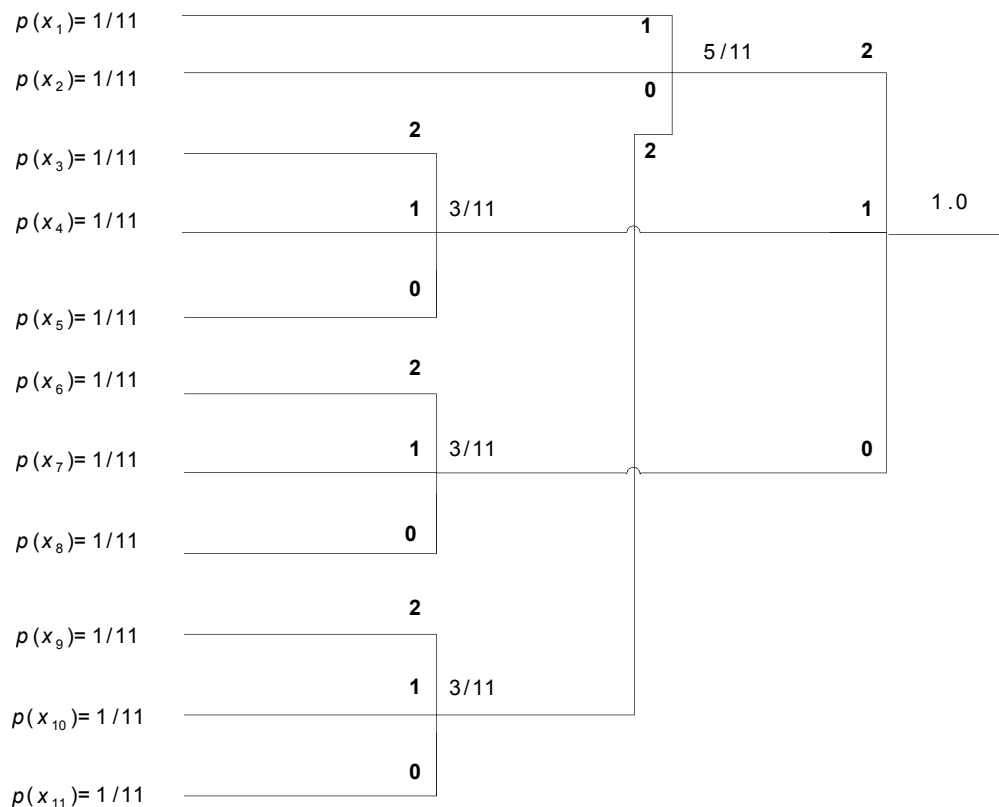
$$H(X) = 3,4594 \text{ bit/simbol}$$

$$H(X) = - \sum_{i=1}^n p(x_i) \log_2 p(x_i) = - \sum_{i=1}^n \frac{1}{n} \log_2 \frac{1}{n} = -n \cdot \frac{1}{n} \log_2 \frac{1}{n} = \log_2 n$$

$$n = 2^{H(X)} = 2^{3,4594} = 11$$

Iz toga jasno slijedi :

$$p(x_1) = p(x_2) = \dots = p(x_{11}) = \frac{1}{11}$$



U tablici su prikazani simboli sa pripadajućim kodnim riječima i njihovim duljinama za ternarno kodiranje

simbol ( $x_i$ )	vjerojatnost pojavljivanja $p(x_i)$	kodna riječ $C(x_i)$	duljina kodne riječi $l(x_i)$
$x_1$	1/11	21	2
$x_2$	1/11	20	2
$x_3$	1/11	12	2
$x_4$	1/11	11	2
$x_5$	1/11	10	2
$x_6$	1/11	02	2
$x_7$	1/11	01	2
$x_8$	1/11	00	2
$x_9$	1/11	222	3
$x_{10}$	1/11	221	3

$x_{11}$	1/11	220	3
----------	------	-----	---

Efikasnost koda računa se prema izrazu:

$$\varepsilon_{(3)} = \frac{H_{(3)}(X)}{L_{(3)}(X)}$$

Proračunajmo potrebne veličine:

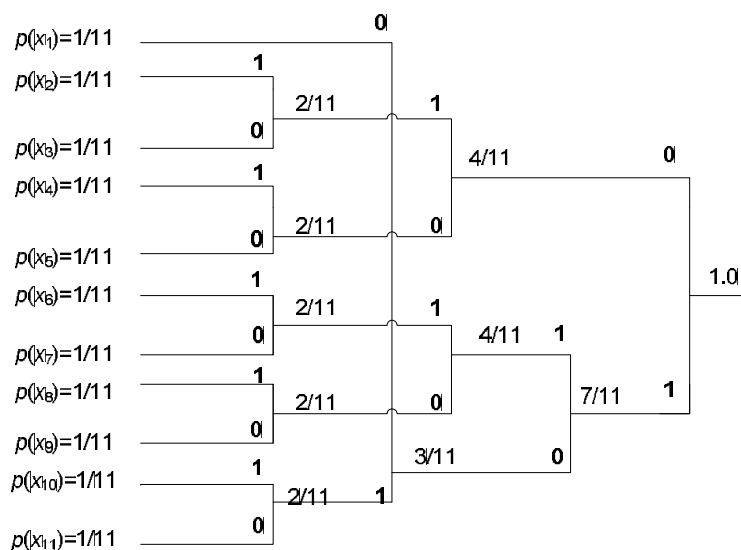
$$H_{(3)}(X) = - \sum_{i=1}^{11} p(x_i) \log_3 p(x_i) = -\log_3 \frac{1}{11} = 2,183 \frac{\text{tern. simbola}}{\text{simbol}}$$

$$L_{(3)}(X) = \sum_{i=1}^{11} p(x_i) l_i = 2,273 \frac{\text{tern. simbola}}{\text{simbol}}$$

Naposljetku:

$$\varepsilon_{(3)} = \frac{H_{(3)}(X)}{L_{(3)}(X)} = \frac{2,183}{2,273} = 0,9604$$

Potrebno je ponovno provesti postupak Huffmanovog kodiranja – ovaj put binarno, kako je prikazano na slici. U tablici su prikazane nove kodne riječi s pripadajućim duljinama.



simbol ( $x_i$ )	vjerojatnost pojavljivanja $p(x_i)$	kodna riječ $C(x_i)$	duljina kodne riječi $l(x_i)$
$x_1$	1/11	100	3
$x_2$	1/11	011	3
$x_3$	1/11	010	3
$x_4$	1/11	001	3
$x_5$	1/11	000	3

$x_6$	1/11	1111	4
$x_7$	1/11	1110	4
$x_8$	1/11	1101	4
$x_9$	1/11	1100	4
$x_{10}$	1/11	1011	4
$x_{11}$	1/11	1010	4

Efikasnost koda računamo prema izrazu:

$$\varepsilon = \frac{H(X)}{L(X)}$$

$$H(X) = - \sum_{i=1}^{11} p(x_i) \log_2 p(x_i) = -\log_2 \frac{1}{11} = 3,459 \frac{\text{bit}}{\text{simbol}}$$

$$L(X) = \sum_{i=1}^{11} p(x_i) l_i = 3,546 \frac{\text{bit}}{\text{simbol}}$$

$$\varepsilon = \frac{H(X)}{L(X)} = \frac{3,459}{3,546} = 0,9755$$

$$\Delta\varepsilon = \varepsilon - \varepsilon_{(3)} = 0,9755 - 0,9604 = 0,0151$$

Obzirom da vrijedi  $\Delta\varepsilon > 0$ , to je binarno kodiranje efikasnije od ternarnog.

**Zadatak 5:** Koristeći algoritam LZ77 kodirana je poruka aaaabbbccd\*, uzimajući pri tome da je maksimalna duljina posmičnog prozora 6, a prozora za kodiranje 5 simbola. Odredite treću trojku kodirane poruke. **Napomena:** znak "\*" označava kraj slijeda.

a) (1,2,c)

b) (1,1,a)

c) (1,2,a)


d) (1,1,b)

*Postupak rješavanja:*

<u>aaaabbbccd*</u>	(0,0,a)
<b>a</b> <u>aaaabbbccd*</u>	(1,3,b)
<b>aa</b> <u>aaabbbccd*</u>	(1,2,c)
<b>aaa</b> <u>abbbccd*</u>	(1,1,d)
<b>aaaabbb</b> <u>ccd*</u>	(0,0,*)

**Zadatak 6:** U kontrolnoj stanici za daljinska mjerenja nalaze se dva instrumenta  $A_1$  i  $A_2$ . Instrument  $A_1$  ima skalu sa 100 podjeljaka i njegovo se pokazivanje mijenja svakih 0,05 s. Instrument  $A_2$  ima skalu s 10 podjeljaka, a njegovo se pokazivanje mijenja svakih 0,01 s. Sve

vrijednosti mjerenih veličina su jednako vjerojatne. Kolika je prosječna količina informacije (bit/s) koju iz kontrolne stanice treba prenijeti u centralnu stanicu C u jedinici vremena?



- a) 333 bit/s
- b) 100 bit/s
- c) 133 bit/s
- d) 466 bit/s

*Postupak rješavanja:*

Prosječna količina informacije koju treba prenijeti u centralnu stanicu jednaka je prosječnoj količini informacije koju generiraju instrumenti  $A_1$  i  $A_2$ . Promatramo li instrumente kao izvore informacije moramo im pridijeliti nekakvu veličinu koja će ih opisati. To je srednji vlastiti sadržaj informacije koji glasi:

$$I(X) = \sum_{i=1}^n p(x_i) \cdot I(x_i) = - \sum_{i=1}^n p(x_i) \log_2 p(x_i)$$

Srednji vlastiti sadržaj informacije je težinska suma vlastitih sadržaja informacija svih pojedinačnih događaja pri čemu svaki događaj učestvuje s iznosom koji odgovara umnošku vjerojatnosti i vlastitog sadržaja informacije. Uz jednaku vjerojatnost svih simbola  $x_i$  dobije se pojednostavljeni izraz:

$$I(X) = \sum_{i=1}^n \frac{1}{n} \log_2 \left( \frac{1}{n} \right) = \log_2(n)$$

Prema tome, instrumentima  $A_1$  i  $A_2$  odgovaraju srednji vlastiti sadržaji informacije  $I_1$ , odnosno  $I_2$ :

$$I_1(X) = \log_2(100) = 6,64 \text{ bit}$$

$$I_2(X) = \log_2(10) = 3,33 \text{ bit}$$

Prosječna količina informacije koju u jedinici vremena generiraju instrumenti iznosi:

$$C_1 = \frac{I_1(X)}{T_1} = \frac{6,64}{5 \cdot 10^{-2}} = 133 \text{ bit/s}$$

$$C_2 = \frac{I_2(X)}{T_2} = \frac{3,33}{10^{-2}} = 333 \text{ bit/s}$$

Ukupna prosječna količina informacije koju treba prenijeti u centralnu stanicu iznosi:

$$C = C_1 + C_2 = 466 \text{ bit/s}$$

To je ujedno i najveći sadržaj informacije koji se može dobiti uz ovakve karakteristike instrumenata kao izvora informacije. (Neizvjesnost je najveća kada su svi događaji jednako vjerojatni.)

**Zadatak 7:** Prijenos poruka provodi se abecedom koju čini osam različitih simbola. Svaki je simbol fizikalno prikazan signalom trajanja  $\tau = 1 \text{ ms}$ . Vjerojatnosti predaje simbola su:  $p(x_i) =$

$2^{-i}$ ,  $i = 1, 2, \dots, 7$ ,  $p(x_8) = p(x_7)$ . Odredite kapacitet kanala za prijenos poruke bez prisustva smetnji.

- a) 1980 bit/s
- b) 3000 bit/s**
- c) 1,98 bit/s
- d) 3 bit/s

*Postupak rješavanja:*

Entropija izvora iznosi:

Zanima nas maksimalna brzina prijenosa informacije od izvora do odredišta koja se može postići – kapacitet kanala. Sadržaj informacije koji se prenese jednak je transinformaciji,  $H_T$ . Ako s  $F$  označimo frekvenciju pojave signala:  $F = 1/\tau$ , kapacitet kanala možemo izraziti kao:

$$C = \max_{\{p(x_i)\}} F \cdot H_T = F \max_{\{p(x_i)\}} [H(X) - H(X|Y)] \text{ bit/s}$$

pri čemu se traži takva razdioba apriornih vjerojatnosti da se postigne maksimalna brzina prijenosa. Za idealni kanal, bez prisustva smetnji,  $H(X|Y) = 0$ , izraz za kapacitet kanala glasi:

$$C = F \max_{\{p(x_i)\}} [H(X)]$$

Maksimum funkcije  $H(X)$  postiže se uz ravnomjernu razdiobu vjerojatnosti:

$$\max_{\{p(x_i)\}} H(X) = \log_2 8 = 3 \text{ bit/simbol}$$

tako da je kapacitet:

$$C = 3000 \text{ bit/s}$$

**Zadatak 8:** Promatrani informacijski izvor bez memorije generira simbole  $x_i$  iz osmočlane abecede  $X = \{x_1, \dots, x_8\}$ . Pripadajuća razdioba vjerojatnosti pojavljivanja simbola na izlazu izvora određena je sljedećim jednakostima:

$$\sum_{i=1}^8 p(x_i) = 1, P(x_1) = 1/4, P(x_3) = P(x_4) = 1/8, P(x_5) = P(x_6) = P(x_7) = P(x_8) = 1/16$$

Koder informacije, tj. koder izvora, kodira simbole  $x_i$  Shannon-Fanovom tehnikom. Simboli na izlazu koda informacije su binarni simboli  $b_i$  iz skupa  $B = \{0, 1\}$  čije su vjerojatnosti pojavljivanja  $P(b_i = 0) = p_0$  i  $P(b_i = 1) = p_1$ . Koliko iznosi omjer entropije na izlazu koda informacije i entropije na izlazu izvora,  $H(B)/H(X)$ , promatran na jako dugačkom slijedu generiranih simbola? **Napomena:** kodiranje Shannon-Fanovom tehnikom potrebno je provesti na način da se prije samog kodiranja simboli  $x_i$  poredaju sukladno vjerojatnosti  $P(x_i)$ , s time da se na višoj poziciji u početnoj grupi, koja obuhvaća sve simbole  $x_i$ , uvijek nalazi simbol čija je vjerojatnost veća ili jednaka vjerojatnosti simbola na nižoj poziciji u početnoj grupi.

- a) 0,33 (simbol  $x_i$ )/(binarni simbol  $b_i$ )
- b) 0,75 (simbol  $x_i$ )/(binarni simbol  $b_i$ )
- c) 0,364** (simbol  $x_i$ )/(binarni simbol  $b_i$ )
- d) 0,5 (simbol  $x_i$ )/(binarni simbol  $b_i$ )

*Postupak rješavanja:*

Na temelju zadanih vjerojatnosti i uvjeta vrijedi  $P(x_2) = 1/4$ . Poredamo simbole po padajućim vjerojatnostima i kodiramo Shannon-Fanovom tehnikom.



simbol	vjerojatnosti	1. korak	2. korak	3. korak	4. korak	$C(x_i)$	$l_i$
$x_1$	0,25	0	0			00	2
$x_2$	0,25	0	1			01	2
$x_3$	0,125	1	0	0		100	3
$x_4$	0,125	1	0	1		101	3
$x_5$	0,0625	1	1	0	0	1100	4
$x_6$	0,0625	1	1	0	1	1101	4
$x_7$	0,0625	1	1	1	0	1110	4
$x_8$	0,0625	1	1	1	1	1111	4

Entropija simbola na ulazu kodera,  $H(X)$  iznosi:

$$H(X) = -\sum_{i=1}^8 P(x_i) \log_2(P(x_i)) = -\left[2 \cdot \frac{1}{4} \log_2\left(\frac{1}{4}\right) + 2 \cdot \frac{1}{8} \log_2\left(\frac{1}{8}\right) + 4 \cdot \frac{1}{16} \log_2\left(\frac{1}{16}\right)\right] = 2 \frac{3}{4} \frac{\text{bit}}{\text{simbol } x_i}$$

a, srednja duljina kodne riječi  $L_{\text{sr}}$  iznosi:

$$L_{\text{sr}} = \sum_{i=1}^8 l_i P(x_i) = 2 \cdot 2 \cdot \frac{1}{4} + 2 \cdot 3 \cdot \frac{1}{8} + 4 \cdot 4 \cdot \frac{1}{16} = 2 \frac{3}{4} \frac{\text{bit}}{\text{simbol } x_i}$$

Za određivanje entropije simbola na izlazu kodera,  $H(B)$  potrebno je poznavati vjerojatnosti  $p_0$  i  $p_1$ . Ako se radi o jako dugačkom nizu generiranih simbola, te vjerojatnosti određujemo sljedećim izrazima:

$$p_0 = \frac{\sum_{i=1}^8 n_{0i} P(x_i)}{L_{\text{sr}}} = \frac{2 \cdot \frac{1}{4} + 1 \cdot \frac{1}{4} + 2 \cdot \frac{1}{8} + 1 \cdot \frac{1}{8} + 2 \cdot \frac{1}{16} + 1 \cdot \frac{1}{16} + 1 \cdot \frac{1}{16}}{2 \frac{3}{4}} = \frac{\frac{22}{16}}{\frac{11}{4}} = \frac{1}{2},$$

$$p_1 = \frac{\sum_{i=1}^8 n_{1i} P(x_i)}{L_{\text{sr}}} = \frac{1 \cdot \frac{1}{4} + 1 \cdot \frac{1}{8} + 2 \cdot \frac{1}{8} + 2 \cdot \frac{1}{16} + 3 \cdot \frac{1}{16} + 3 \cdot \frac{1}{16} + 4 \cdot \frac{1}{16}}{2 \frac{3}{4}} = \frac{\frac{22}{16}}{\frac{11}{4}} = \frac{1}{2}$$

pri čemu za broj binarnih nula,  $n_{0i}$ , odnosno broj binarnih jedinica,  $n_{1i}$ , u svakoj kodnoj riječi  $C(x_i)$ ,  $i = 1, \dots, 8$ , vrijedi:  $n_{0i} + n_{1i} = l_i$ . Dakle,  $p_0 = p_1 = 1/2$ , pa  $H(B)$  iznosi:

$$H(B) = \sum_{i=0}^1 p_i \log_2(p_i) = 1 \frac{\text{bit}}{\text{simbol } b_i}$$

Dakle,  $H(B)/H(X) = 1/(11/4) = 4/11 \approx 0,364$  (simbol  $x_i$ )/(binarni simbol  $b_i$ ).

**Zadatak 9:** Promatrajte informacijski izvor bez memorije koji generira poruke sastavljene od simbola  $x_i$  iz  $N$ -članog skupa simbola  $X = \{x_1, \dots, x_N\}$  čije su vjerojatnosti pojavljivanja  $P(x_i)$ . Te su vjerojatnosti određene sljedećim izrazima:

$$\sum_{i=1}^N P(x_i) = 1,$$

$$P(x_i) = \frac{1}{2}, \frac{P(x_i)}{P(x_{i+1})} = 2, \forall i = 1, \dots, N-2$$

Poruke sastavljene od sljedova simbola  $x_i$  kodiraju se aritmetičkim kodom  $C$ . Pri kodiranju se koristi sljedeće pravilo: za svaku poruku duljine  $M$  simbola,  $p_{Mj}$ ,  $j = 1, \dots, N^M$ ,  $M \in \mathbf{N}$ , u podintervalu dobivenom postupkom kodiranja, čija je duljina  $d(p_{Mj})$ , uvijek se odabire vrijednost na sredini tog podintervala, te se tako dobivena vrijednost pretvara u binarni broj od kojeg se za kodnu riječ  $C(p_{Mj})$  uzimaju znamenke desno od decimalnog zareza. Ako pretpostavimo da je kôd  $C$  ujedno i prefiksni, odredite koliko binarnih znamenaka sadrži najdulja kodirana poruka sastavljena od  $M$  simbola  $x_i$ .

- a)  $N \cdot M$  bita
- b)  $N \cdot M + 1$  bita
- c)  $(N - 1) \cdot M$  bita
- d)  $(N - 1) \cdot M + 1$  bita**

*Postupak rješavanja:*

Iz zadanih uvjeta očito je da vrijedi  $P(x_{N-1}) = P(x_N) = 1/(2^{N-1})$ . Prilikom aritmetičkog kodiranja poruka sastavljenih od  $M$  simbola  $x_i$ , koje jednoznačno zapisujemo kao  $p_{Mj} = (x_{1i}, x_{2i}, \dots, x_{Mi})$ ,  $x_{ki} \in X$ ,  $\forall k = 1, \dots, M$ ,  $\forall i = 1, \dots, N$ ,  $\forall j = 1, \dots, N^M$ , duljina  $d(p_{Mj})$  podintervala pridruženog poruci  $p_{Mj}$  određuje se množenjem vjerojatnosti simbola od kojih je poruka sastavljena. Nadalje, ako pretpostavimo da je kôd  $C$  prefiksni, tada se prilikom formiranja kodne riječi za poruku  $p_{Mj}$  uzima broj bita  $l(p_{Mj})$  određen sljedećim izrazom:

$$l(p_{Mj}) = \left\lceil \log_2 \left( \frac{1}{d(p_{Mj})} \right) \right\rceil + 1 \text{ bit}$$

Duljina poruke će očito biti maksimalna, ako poruka sadrži isključivo simbole čije su vjerojatnosti pojavljivanja  $1/(2^{N-1})$ , tj. najmanje moguće, a to su simboli  $x_k$ ,  $k \in \{N-1, N\}$ . Dakle, vrijedi:

$$\max_j l(p_{Mj}) = \max_j \left( \left\lceil \log_2 \left( \frac{1}{d(p_{Mj})} \right) \right\rceil + 1 \right) = \left\lceil \log_2 \left( \frac{1}{(1/2^{N-1})^M} \right) \right\rceil + 1 = (N-1) \cdot M + 1 \text{ bit}$$

**Zadatak 10:** Informacijski izvor generira simbole hrvatske abecede. Slijed se kodira kodom LZW. Prije početka kodiranja u memoriju koda pohranjeni su zapisi oblika (indeks, znak) za sva slova abecede i za znakove koji se u tekstu mogu pojaviti. Razmotrimo poseban slučaj (npr. izvor je u kvaru) kad izvor generira isključivo slovo **a**. Ako izvor izgenerira točno 4951 slovo **a**, koliko će pri tome biti novih zapisa oblika (indeks, riječ) u rječniku? **Pojašnjenje:** svaki slijed sastavljen od uzastopnih slova **a**, npr. **aaa**, a koji nije od ranije sadržan u rječniku, smatra se jednim novim zapisom u rječnik, oblika (indeks, riječ).

- a) 98
- b) 100**
- c) 102
- d) 4950

*Postupak rješavanja:*

Ako izvor kodira slijed uzastopnih slova **a** moguće je zamijetiti sljedeću pravilnost:

1) kad izvor kodira prvo slovo **a** (na samom početku dugačkog slijeda), ne zapisuje ništa u rječnik jer za slovo **a** već postoji zapis u rječniku;

2) zatim uzima sljedeće slovo **a** i u rječnik zapisuje simbol **aa** te njemu pripadajući indeks (to je jedan novi zapis);

3) zatim uzme to drugo slovo **a** i spaja ga s naredna dva slova **a** te u rječnik zapisuje **aaa**

4) itd.

Ako to prikazemo tablicom, vidljiva je sljedeća pravilnost:

iteracija	broj uzastopnih slova <b>a</b>	ukupan broj novih zapisa u rječniku
$i$	$N_i(\mathbf{a})$	$x_i$
1	1	0
2	2	1
3	4	2
4	7	3
5	11	4
6	16	5

Broj uzastopnih slova **a** (lijevi stupac tablice),  $N_i(\mathbf{a})$ , se povećava svaki puta za ukupan broj novih zapisa,  $x_i$ , tj. vrijedi:  $N_i(\mathbf{a}) - N_{i-1}(\mathbf{a}) = x_i$ , za  $i \geq 2$ . Iz toga možemo zaključiti da vrijedi:

$$N_M = \sum_{i=2}^M x_i + N_1 = \sum_{i=1}^{M-1} i + 1 = 1 + \frac{M \cdot (M-1)}{2}$$

$$M^2 - M - 2(N_M - 1) = 0$$

$$M_{1,2} = \frac{1 \pm \sqrt{1 + 8(N_M - 1)}}{2}$$

Očito je da samo jedno rješenje ima smisla, pa konačno vrijedi:

$$M = \frac{1 + \sqrt{1 + 8(N_M - 1)}}{2}$$

Dakle, ako je  $N_M = 4951$ , tada je  $M = 100$ .